

# Laporan Praktikum Minggu Ke-4 Kontrol Cerdas

## Minggu ke-4

Nama : Putu Sriwahyuningsih  
NIM : 224308066  
Kelas : TKA 7C  
Akun Github : <https://github.com/putusriwahyu>

### 1. Judul Percobaan

Reinforcement Learning for Autonomous Control

### 2. Tujuan Percobaan

- Memahami konsep dasar Reinforcement Learning (RL) dalam sistem kendali.
- Mengimplementasikan agen RL menggunakan algoritma Deep Q-Network (DQN).
- Menggunakan OpenAI Gym sebagai simulasi lingkungan untuk pelatihan RL.
- Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.

### 3. Landasan Teori

Kecerdasan buatan atau Artificial Intelligence (AI) adalah sistem yang mempelajari bagaimana membuat komputer dapat berpikir, belajar, dan bertindak seperti manusia (Marsella et al., 2023). Reinforcement Learning (RL) merupakan salah satu metode AI atau Machine Learning yang memiliki ciri khas dalam hal pembelajaran langsung pada lingkungan. Artinya reinforcement learning (RL) adalah metode pembelajaran di mana agen belajar mengambil keputusan melalui interaksi dengan lingkungan. Agen memperoleh reward atau penalty sebagai umpan balik dari tindakannya, sehingga ia dapat mengoptimalkan strategi untuk mencapai tujuan tertentu.

Pada dasarnya memungkinkan mesin atau agen mempelajari tindakannya berdasarkan timbal balik dari lingkungan sehingga dapat beradaptasi dengan lingkungan seiring dengan berjalannya waktu. Prinsip yang digunakan dalam metode ini didasarkan pada teori reinforcement yang pada intinya adalah

‘konsekuensi mempengaruhi tindakan’. Ada 3 prinsip dasar pada teori reinforcement yakni konsekuensi yang berakibat baik mendorong terjadinya tindakan, konsekuensi yang berakibat buruk mendorong berkurangnya tindakan dan konsekuensi yang tidak ada dampaknya tidak mempengaruhi tindakan.

Selain DQN, terdapat pula Policy Gradient Methods yang menjadi salah satu pendekatan penting dalam Reinforcement Learning. Berbeda dengan Q-Learning maupun DQN yang berfokus pada estimasi nilai Q, metode Policy Gradient langsung mempelajari kebijakan (policy) yang memetakan keadaan (state) ke tindakan (action). Dengan pendekatan ini, agen dapat menghasilkan strategi yang lebih halus, terutama pada masalah dengan ruang aksi kontinu. Metode ini menggunakan fungsi objektif yang dioptimalkan melalui teknik gradient ascent untuk meningkatkan probabilitas tindakan yang menghasilkan reward tinggi. Beberapa varian dari metode ini, seperti REINFORCE, Actor-Critic, hingga Proximal Policy Optimization (PPO), semakin memperluas kemampuan RL dalam menangani permasalahan kompleks, termasuk di bidang robotika, sistem keuangan, hingga kecerdasan buatan generatif (Terven, 2025).

Di sisi lain, perkembangan teknologi Reinforcement Learning juga erat kaitannya dengan pemanfaatan perangkat lunak pendukung. Salah satu pustaka yang banyak digunakan adalah TensorFlow dan PyTorch untuk implementasi jaringan saraf dalam algoritma RL modern. Kedua framework ini memungkinkan pengembang untuk membangun, melatih, dan menguji model deep learning secara efisien. Selain itu, library seperti Gym dari OpenAI menyediakan berbagai lingkungan simulasi standar yang digunakan untuk menguji algoritma RL, mulai dari permainan sederhana hingga simulasi fisik yang kompleks. Kehadiran ekosistem perangkat lunak tersebut mempercepat proses riset dan pengembangan, serta memudahkan mahasiswa, peneliti, maupun praktisi untuk melakukan eksperimen RL pada berbagai domain aplikasi.

Dengan demikian, penerapan Reinforcement Learning tidak hanya bergantung pada konsep algoritma semata, tetapi juga pada integrasi dengan perangkat lunak, bahasa pemrograman, dan pustaka pendukung. Kombinasi antara teori RL yang kuat, algoritma canggih seperti DQN dan Policy Gradient, serta dukungan teknologi pemrograman seperti Python, OpenCV, TensorFlow, dan PyTorch menjadikan RL sebagai salah satu metode paling menjanjikan dalam mewujudkan sistem cerdas yang adaptif dan otonom.

#### 4. Analisis dan Diskusi

- **Analisis**

1. Bagaimana performa agen dalam mengontrol environment CartPole?

Agen RL pada CartPole umumnya bisa belajar menjaga tiang tetap seimbang di atas kereta dengan baik. Awalnya agen sering gagal karena masih coba-coba, tetapi setelah beberapa episode pelatihan, agen bisa menemukan strategi yang stabil sehingga tiang bisa bertahan tegak lebih lama.

2. Bagaimana perubahan parameter (gamma, epsilon, learning rate) mempengaruhi kinerja agen?

Gamma yang tinggi membuat agen lebih fokus pada hasil jangka panjang, sedangkan gamma rendah membuat agen hanya mengejar reward cepat. Epsilon tinggi berarti agen lebih banyak coba-coba, sedangkan epsilon rendah membuat agen lebih sering memakai strategi yang sudah bagus; biasanya dipakai epsilon decay agar seimbang. Learning rate tinggi membuat agen belajar cepat tapi bisa tidak stabil, sedangkan learning rate rendah membuat pembelajaran lebih lambat tapi stabil.

3. Apa tantangan yang muncul selama pelatihan agen RL?

Tantangan utamanya adalah menjaga keseimbangan antara eksplorasi dan eksploitasi. Kalau terlalu banyak eksplorasi, agen lama belajar; kalau terlalu cepat eksploitasi, agen bisa terjebak pada strategi yang kurang optimal. Selain itu, pembelajaran bisa tidak stabil dan semakin sulit kalau environment makin kompleks.

- **Diskusi**

1. Apa perbedaan utama antara Reinforcement Learning dan Supervised Learning dalam sistem kendali?

Supervised learning belajar dari data yang sudah ada jawabannya, sedangkan reinforcement learning belajar lewat trial and error dari reward atau hukuman. Jadi RL lebih cocok untuk pengambilan keputusan adaptif, sementara supervised cocok untuk prediksi.

2. Bagaimana strategi eksplorasi dan eksploitasi dapat dioptimalkan pada

agen RL?

Strateginya bisa dengan epsilon-greedy yang perlahan diturunkan (decay), sehingga awalnya banyak coba-coba lalu makin fokus pada strategi terbaik. Bisa juga pakai softmax atau metode lain agar agen tetap seimbang antara coba-coba dan memanfaatkan pengetahuan.

3. Potensi aplikasi lain dari RL dalam sistem kendali nyata apa saja yang dapat diimplementasikan?

RL bisa dipakai di banyak bidang, misalnya untuk kendaraan otonom agar bisa mengambil keputusan di jalan, robot industri yang bisa beradaptasi saat bekerja, pengaturan lalu lintas cerdas, optimasi distribusi energi, hingga kontrol drone untuk pemetaan dan pengiriman barang.

## **5. Assignment**





Dalam praktikum ini dilakukan modifikasi program dengan menambahkan teknik target network untuk meningkatkan stabilitas pelatihan algoritma Deep Q-Network (DQN). Agen kemudian diuji pada environment lain seperti MountainCar-v0 untuk dibandingkan performanya dengan CartPole-v1. Implementasi agen Reinforcement Learning (RL) ini memanfaatkan DQN yang dilengkapi dengan memori replay dan strategi epsilon-greedy, sehingga pembelajaran menjadi lebih stabil dan efisien. Kelebihan sistem ini terletak pada adanya visualisasi real-time menggunakan Pygame, yang memudahkan pemahaman intuitif mengenai interaksi agen dengan lingkungan, serta plotting grafik dinamis dengan Matplotlib yang memungkinkan pemantauan kemajuan pelatihan secara langsung. Selain itu, penggunaan Keras dan TensorFlow mempermudah pembangunan serta pelatihan jaringan saraf tiruan untuk agen.


Meski demikian, terdapat beberapa kekurangan pada implementasi ini. Kompleksitas visualisasi dapat memperlambat proses pelatihan dan menambah beban komputasi, terutama ketika dijalankan pada perangkat dengan sumber daya terbatas. Selain itu, ketergantungan pada berbagai pustaka eksternal membuat program lebih berat dari sisi setup dan eksekusi. Waktu pelatihan juga relatif lebih lama, khususnya pada environment yang kompleks seperti

MountainCar-v0, yang membutuhkan strategi kontrol berbasis reward jangka panjang agar agen mampu mencapai tujuan.

## 6. Data dan Output Hasil Pengamatan

| No | Variabel                        | Hasil Pengamatan                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 |
|----|---------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|    |                                 | CartPole-v1                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    | MountainCar-v0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  |
| 1. | Waktu Training                  | CartPole lebih cepat mencapai performa bagus hanya dalam beberapa ratus episode.                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               | MountainCar butuh episode lebih banyak agar hasilnya stabil.                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    |
| 2. | Jumlah Episode yang di training | Cartpole ditraining hingga 1000 episode<br><pre># Pilih environment (CartPole-v1) env = gym.make("CartPole-v1")  state_size = env.observation_space.shape[0] action_size = env.action_space.n  agent = DQNAgent(state_size, action_size) episodes = 1000 batch_size = 32</pre>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 | MountainCar ditraining hingga 1000 episode<br><pre>if __name__ == "__main__": # pakai __name__     env = gym.make("MountainCar-v0", render_mode="human")     state_size = env.observation_space.shape[0]     action_size = env.action_space.n     agent = DQNAgent(state_size, action_size)     episodes = 1000     batch_size = 32</pre>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       |
| 3. | Nilai Awal dan Maksimum         | Nilai bervariasi tergantung seberapa lama tiang tetap seimbang (maksimum 200)<br><pre>n other operations, rebuild TensorFlow with the app Episode: 1/1000, Score: 22, Epsilon: 1.00 Episode: 2/1000, Score: 18, Epsilon: 1.00 Episode: 3/1000, Score: 16, Epsilon: 0.99 Episode: 4/1000, Score: 20, Epsilon: 0.99 Episode: 5/1000, Score: 21, Epsilon: 0.99 Episode: 6/1000, Score: 16, Epsilon: 0.98 Episode: 7/1000, Score: 19, Epsilon: 0.98 Episode: 8/1000, Score: 30, Epsilon: 0.97 Episode: 9/1000, Score: 9, Epsilon: 0.97 Episode: 10/1000, Score: 41, Epsilon: 0.96 Episode: 11/1000, Score: 30, Epsilon: 0.96 Episode: 12/1000, Score: 9, Epsilon: 0.95 Episode: 13/1000, Score: 12, Epsilon: 0.95 Episode: 14/1000, Score: 13, Epsilon: 0.94</pre> | Skor awal mencapai 199 karena maksimal langkah dalam satu episode adalah 200.<br><pre>ther operations, rebuild TensorFlow with the app Episode: 1/1000, Score: 199, Epsilon: 1.00 Episode: 2/1000, Score: 199, Epsilon: 0.99 Episode: 3/1000, Score: 199, Epsilon: 0.99 Episode: 4/1000, Score: 199, Epsilon: 0.99 Episode: 5/1000, Score: 199, Epsilon: 0.98 Episode: 6/1000, Score: 199, Epsilon: 0.98 Episode: 7/1000, Score: 199, Epsilon: 0.97 Episode: 8/1000, Score: 199, Epsilon: 0.97 Episode: 9/1000, Score: 199, Epsilon: 0.96 Episode: 10/1000, Score: 199, Epsilon: 0.96 Episode: 11/1000, Score: 199, Epsilon: 0.95 Episode: 12/1000, Score: 199, Epsilon: 0.95 Episode: 13/1000, Score: 199, Epsilon: 0.94 Episode: 14/1000, Score: 199, Epsilon: 0.94 Episode: 15/1000, Score: 199, Epsilon: 0.93 Episode: 16/1000, Score: 199, Epsilon: 0.93 Episode: 17/1000, Score: 199, Epsilon: 0.92</pre> |
| 4. | Epsilon                         | Nilai epsilon ( $\epsilon$ ) menurun seiring dengan proses agen belajar<br><pre>Epsilon: 0.61 Epsilon: 0.60 Epsilon: 0.60 Epsilon: 0.59 Epsilon: 0.59 Epsilon: 0.59 Epsilon: 0.58 Epsilon: 0.58 Epsilon: 0.58 Epsilon: 0.57 Epsilon: 0.57 Epsilon: 0.57 Epsilon: 0.56 Epsilon: 0.56 Epsilon: 0.56 Epsilon: 0.55</pre>                                                                                                                                                                                                                                                                                                                                                                                                                                          | Nilai epsilon ( $\epsilon$ ) juga menurun seiring dengan proses agen belajar<br><pre>Epsilon: 0.10 Epsilon: 0.10 Epsilon: 0.10 Epsilon: 0.10 Epsilon: 0.10 Epsilon: 0.10 Epsilon: 0.10 Epsilon: 0.10 Epsilon: 0.09 Epsilon: 0.09 Epsilon: 0.09 Epsilon: 0.09</pre>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                              |
| 5. | Kinerja                         | Agen semakin stabil dengan                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     | Agen masih menghadapi                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           |

|    |                  |                                                                                                                                                                               |                                                                                                                                                                                              |
|----|------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|    | Agen             | skor yang makin tinggi                                                                                                                                                        | tantangan untuk mencapai puncak bukit.                                                                                                                                                       |
| 6. | Hasil Test Agen  | <p>Agen mampu menjaga keseimbangan tiang lebih lama dari episode ke episode</p>              | <p>Agen masih sering gagal mencapai puncak, reward cenderung stagnan</p>                                  |
| 7. | Kondisi Berhasil | Episode berakhir jika tiang jatuh atau batas langkah maksimum tercapai                                                                                                        | Episode berakhir jika mobil berhasil sampai puncak bukit (flag)                                                                                                                              |
| 8. | Hasil Output     | <p>Visualisasi menunjukkan tiang bisa tetap tegak lebih lama, grafik reward meningkat</p>  | <p>Visualisasi menunjukkan mobil sering gagal sampai puncak, grafik reward cenderung stabil di -170</p>  |
| 9. | Hasil Grafik     | Grafik reward naik dari sekitar 70 ke 130+, tren meningkat stabil                                                                                                             | Grafik reward fluktuatif di kisaran -200 s.d. -150, cenderung stabil di sekitar -170                                                                                                         |



Berdasarkan hasil pengamatan, terlihat adanya perbedaan performa yang cukup jelas antara CartPole-v1 dan MountainCar-v0. Pada lingkungan CartPole, agen dapat mencapai performa yang baik hanya dalam beberapa ratus episode, sehingga proses pelatihannya relatif cepat. Hal ini berbeda dengan MountainCar yang membutuhkan episode lebih banyak agar performanya stabil, menandakan bahwa tingkat kesulitan lingkungannya lebih tinggi. Dari segi reward, CartPole menghasilkan nilai yang bervariasi tergantung pada lamanya tiang tetap seimbang, dengan potensi reward maksimum 200. Sebaliknya, pada MountainCar skor awal memang tinggi (199) karena jumlah langkah maksimal dalam satu episode adalah 200, namun nilai reward sulit meningkat lebih lanjut meskipun jumlah episode bertambah.

Nilai epsilon pada kedua environment menurun seiring bertambahnya episode, yang menunjukkan bahwa agen semakin banyak belajar dari pengalaman dan beralih dari tahap eksplorasi menuju eksploitasi. Kinerja agen pada CartPole cenderung stabil dan meningkat, di mana agen mampu menjaga keseimbangan tiang lebih lama sehingga reward terus naik. Sedangkan pada MountainCar, agen masih mengalami kesulitan untuk mencapai puncak bukit sehingga reward cenderung stagnan.

Hasil pengujian memperlihatkan bahwa pada CartPole agen mampu mempertahankan tiang tetap tegak lebih lama, didukung oleh visualisasi dan grafik reward yang menunjukkan tren meningkat stabil dari sekitar 70 hingga lebih dari 130. Sementara itu, pada MountainCar agen sering kali gagal mencapai puncak bukit, terlihat dari visualisasi mobil yang bolak-balik tanpa konsisten sampai tujuan dan grafik reward yang berfluktuasi pada kisaran -200 hingga -150 serta cenderung stabil di sekitar -170. Dari hasil ini dapat disimpulkan bahwa CartPole lebih mudah dipelajari dan diadaptasi oleh agen, sedangkan MountainCar lebih menantang

karena agen harus menerapkan strategi khusus untuk mencapai hasil yang optimal.

## **7. Kesimpulan**

Berdasarkan praktikum dan analisis yang telah dilakukan, maka dapat diambil kesimpulan yaitu:

- a. Pada CartPole-v1, agen mampu belajar dengan cepat dan menunjukkan peningkatan performa yang stabil. Reward meningkat seiring bertambahnya episode, menandakan agen berhasil menemukan strategi yang optimal.
- b. Pada MountainCar-v0, agen masih kesulitan mencapai puncak bukit sehingga reward cenderung stagnan pada nilai rendah. Hal ini menunjukkan performa agen belum optimal.
- c. Secara keseluruhan, CartPole-v1 lebih mudah dipelajari dibandingkan MountainCar-v0, karena tingkat kesulitan lingkungannya lebih rendah.
- d. Untuk MountainCar-v0, diperlukan strategi tambahan seperti tuning hyperparameter, eksplorasi yang lebih efektif, atau algoritma lain agar agen dapat mencapai hasil yang lebih baik.

## **8. Saran**

- a. Untuk environment MountainCar-v0, disarankan melakukan tuning hyperparameter seperti learning rate, gamma, dan epsilon decay agar agen dapat belajar lebih efektif.
- b. Dapat menggunakan strategi eksplorasi tambahan (misalnya softmax action selection atau epsilon decay yang lebih lambat) agar agen lebih banyak mencoba alternatif solusi.
- c. Mengoptimalkan waktu pelatihan dengan perangkat keras yang lebih baik atau menonaktifkan visualisasi real-time agar proses training lebih cepat.

## **9. Daftar Pustaka**

- Marsella, M., Wijaya, C. S., Wijaya, I., Shidqi, M. T., & Novita, D. (2023). ANALISIS IMPLEMENTASI ARTIFICIAL INTELLIGENCE UNTUK BISNIS: SYSTEMATIC LITERATURE REVIEW. *DEVICE: JOURNAL OF INFORMATION SYSTEM, COMPUTER SCIENCE AND INFORMATION TECHNOLOGY*, 4(2), 133–145. <https://doi.org/10.46576/device.v4i2.4037>
- Terven, J. (2025). Deep Reinforcement Learning: A Chronological Overview and Methods. *AI*, 6(3), 46. <https://doi.org/10.3390/ai6030046>